

Министерство науки и высшего образования Российской
Федерации
Федеральное государственное бюджетное образовательное
учреждение высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

Лабораторная работа № 4

по дисциплине «Анализ Алгоритмов»

Тема Параллельные вычисления на основе нативных потоков

Студент Поляков А.И.

Группа ИУ7-52Б

Преподаватели Волкова Л.Л.

Москва, 2024

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	3
1 Входные и выходные данные	3
2 Преобразование входных данных в выходные	3
3 Примеры работы программы	6
4 Тестирование	7
5 Описание исследования	7
ЗАКЛЮЧЕНИЕ	8
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	10

ВВЕДЕНИЕ

Параллелизм описывает одновременное выполнение различных последовательностей действий [1]. Следовательно, параллельные вычисления подразумевают выполнение операций одновременно. Распараллеливание вычислений может повысить временную эффективность программы на многопроцессорных системах и даже на однопроцессорных, если программа часто простаивает, ожидая ввода-вывода [2].

В современных системах параллельность может быть реализована с использованием потоков или процессов. При этом важно учитывать, что программы часто работают не в строгом параллелизме, а конкурентно, выполняясь последовательно с частым переключением между задачами [2].

Цель данной работы — разработка программного обеспечения для скачивания страниц с сайта vkusnoprigotovim.ru.

Задачи работы включают:

- создание ПО для однопоточного скачивания и парсинга;
- создание многопоточного ПО для скачивания и парсинга;
- исследование временных характеристик разработанных программ.

1 Входные и выходные данные

Входными данными для программы является адрес главной страницы ресурса vkusnoprigotovim.ru. Выходными данными является директория с файлами, которые содержат скачанные данные со страниц в текстовом формате.

2 Преобразование входных данных в выходные

Для реализации ПО был использован язык C#, поддерживающий нативную многопоточность. Класс `System.Threading.Thread` представляет собой абстракцию над системными потоками, позволяющую вызывать их из кода

программы [3]. Вызов метода Thread.Start влечет за собой создание системного потока, отдельного от основного потока программы [4].

Алгоритм обработки набора страниц

- 1) Инициализация начальных параметров: начальный URL, директория для сохранения страниц, максимальное количество страниц и путь для сохранения результатов в формате CSV.
- 2) Определение количества потоков для тестирования и числа повторений тестов.
- 3) Открытие CSV-файла для записи результатов и добавление заголовка.
- 4) Проведение тестов в последовательном режиме:
 - запуск цикла тестирования на заданное количество повторений;
 - инициализация объекта **WebScrapper** с настройками для последовательного режима;
 - измерение времени выполнения операции с помощью **Stopwatch**;
 - сохранение времени выполнения теста.
- 5) Запись среднего времени выполнения последовательного режима в CSV и вывод в консоль.
- 6) Проведение тестов в параллельном режиме с использованием различных значений количества потоков:
 - запуск цикла по каждому значению количества потоков;
 - инициализация объекта **WebScrapper** с настройками для параллельного режима;
 - измерение времени выполнения операций для каждого количества потоков;
 - сохранение времени выполнения теста.
- 7) Запись среднего времени выполнения параллельного режима для каждого количества потоков в CSV и вывод в консоль.
- 8) Завершение тестирования и закрытие CSV-файла.

- 9) Вывод сообщения о завершении работы и сохранении результатов.

Ниже представлено описание работы класса `WebScraper`.

- 1) Инициализация объекта `WebScraper` с базовым URL, максимальным количеством страниц, директорией для сохранения и количеством потоков.
- 2) Создание очереди URL и списка для отслеживания обработанных URL.
- 3) Начало работы скрапинга с проверкой на параллельный режим:
 - в параллельном режиме инициализация и запуск нескольких потоков, каждый из которых выполняет метод `ProcessQueueParallel`;
 - в последовательном режиме выполнение метода `ProcessQueueSequential`.
- 4) Обработка страниц в последовательном режиме, извлечение URL из очереди и вызов метода `ProcessPage`.
- 5) Обработка страниц в параллельном режиме:
 - попытка извлечь URL из очереди с помощью семафора;
 - вызов метода `ProcessPage` для обработки страницы.
- 6) Метод `ProcessPage`:
 - проверка URL на соответствие базовому домену и уникальность;
 - запрос страницы и извлечение текста с нужными классами с помощью метода `ExtractTextFromBody`;
 - сохранение содержимого страницы в текстовый файл;
 - извлечение ссылок со страницы и добавление их в очередь, если они еще не обработаны.
- 7) Метод `ExtractTextFromBody` фильтрует текст HTML-страницы по классам и форматирует его.
- 8) Метод `ExtractLinks` извлекает и фильтрует ссылки, соответствующие базовому домену.

3 Примеры работы программы

Один из примеров обработки веб-страниц [5] представлен на рисунках 3.1–3.2.




Рисунок 3.1 – Веб-страница по ссылке [5]

1	Вкусно	приготовить на плите
2	Выпечка	Горячее Десерты Заготовки Закуски Каши Напитки Салаты Соусы Супы
3	Рецепты	
4	Супы	
5	Рецепт фасолевого супа без мяса	
6	фасолевый суп без мяса	
7	Рецепт от: Ануа	
8	• Легкие рецепты	
9	• Фасолевый суп	
10	• Рецепт супов	
11	Рецепт: Простой	
12	Время приготовления:	
13	80 мин	
14	Порций: 6	
15	Калорий:	
16	172 ккал	
17	Кухня: Авторская	
18	Вегетарианство: Постные рецепты	
19	Повод: На обед, Полезный обед	
20	Вы вегетарианец? Соблюдаете пост? А может вам просто захотелось чего-то легкого, без мя	
21	Ингредиенты на шесть порций	
22	Белая фасоль — 2 стак. Картофель — 3 шт. Морковь — 2 шт. Лук репчатый — 2 шт. Чеснок —	
23	Приготовление	
24	Фасоль промыть, замочить на ночь.	
25	Замоченную фасоль еще раз промыть, переложить в кастрюлю с подсоленной водой и варить в	

Рисунок 3.2 – Результат обработки программой

4 Тестирование

Тестирование программы проводилось загрузкой в качестве входных данных 100 ссылок на различные страницы vkusnoprigotovim.ru. При этом отслеживалось количество удачных скачиваний и обработок страницы, а также выборочная ручная проверка 10 случайных выходных файлов.

Тестирование проводилось как для однопоточной реализации, так и для многопоточной, при этом выходные файлы обеих реализаций при тестировании оказались идентичными.

Тестирование было успешно пройдено.

5 Описание исследования

В ходе исследования были собраны данные о временных характеристиках однопоточной и многопоточной реализаций, при этом для многопоточной реализации были собраны данные при количестве потоков равному 1, 2, 4, 8, 16, 32, 64.

Для каждого из вариантов программы выполнение проводилось 10 раз и бралось среднее арифметическое времён, на вход подавался файл с 100 ссылок.

Технические характеристики устройства, на котором проводились замеры:

- процессор: AMD Ryzen 7 5800U (16) @ 4.51 ГГц;
- оперативная память: 16 Гб;
- ядро ОС Linux 6.11.6-zen1-1-zen.

При проведении замеров ноутбук был включён в сеть и были запущены только системные приложения.

Временные характеристики реализаций представлены в таблице 5.1 и на графике 5.1.




Рисунок 5.1 – График временных характеристик разработанных программ

Таблица 5.1 – Временные характеристики разработанных программ (начало)

Кол-во вспомогательных потоков	Время, мс
0	17346
1	19227
2	17761
4	16326
8	12763
16	11771
32	17758
64	19297

ЗАКЛЮЧЕНИЕ

Было разработано программное обеспечение для скачивания страниц с сайта vkusnoprigitovim.ru.

В ходе работы были решены следующие задачи:

- разработано ПО, выполняющее скачивание и парсинг в одном потоке;
- разработано многопоточное ПО, выполняющее скачивание и парсинг;
- исследованы временные характеристики разработанных программ.

В ходе исследования было выявлено, что использование параллельных вычислений на нативных потоках ускоряет программу, однако использование большего числа потоков, чем может выполнять процессор не даёт прироста производительности, а замедляет программу.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. David R. Butenhof Programming with POSIX threads [Текст] / David R. Butenhof — Washington: Library of Congress Cataloging-in-Publication Data, 1997 — 202 с.
2. Таненбаум Э., Бос Х. Современные операционные системы. [Текст] / Таненбаум Э., Бос Х. — 4-е изд.. — СПб.: Питер, 2015 — 1120 с.
3. Joseph Albahari C# 12 in a Nutshell [Текст] / Joseph Albahari — 1-е изд.. — Gravenstein: O'Reilly, 2023 — 1066 с.
4. Jeffrey Richter CLR via C# [Текст] / Jeffrey Richter — 4-е изд.. — Redmond: Microsoft Press, 2012 — 863 с.
5. Аняа Супер Вкусный Рецепт Фасолевого Супа Без Мяса Съедят Всё! / Аняа [Электронный ресурс] // VkusnoPrigotovim.ru : [сайт]. — URL: <https://vkusnoprigotovim.ru/supy/fasolevy-sup-bez-myasa> (дата обращения: 05.11.2024).